

南方科技大学

硕士学位论文开题报告

题目：面向交互式可视分析的多模态智能体
框架研究

院	(系)	计算机科学与工程系
学	科	电子信息
导	师	马昱欣副教授
研	究	生
学	号	12432738
开题报告日期		2025 年 12 月 23 日

研究生院制

目 录

第 1 章 选题背景与研究意义.....	1
1.1 研究背景.....	1
1.2 研究意义.....	2
第 2 章 国内外研究现状.....	3
2.1 机器学习辅助可视化.....	3
2.2 图表视觉问答.....	4
2.3 图形用户界面智能体.....	5
2.3.1 感知：从像素到图像语义的映射.....	5
2.3.2 探索：构建可视化工具的知识库.....	6
2.3.3 规划：复杂可视分析任务的分解.....	6
2.3.4 行动：超高精度的可视界面操控.....	6
2.4 多智能体系统与协同推理.....	7
第 3 章 研究内容.....	9
3.1 构建交互式可视图表的评估基准.....	9
3.2 面向简单通用图表的 GUI Agent.....	10
3.3 面对复杂专用图表的 GUI agent.....	10
第 4 章 研究方案及预期目标.....	12
4.1 总体方案.....	12
4.2 任务一：InterVis-Bench 基准构建.....	12
4.3 任务二：通用图表智能体实现.....	13
4.4 任务三：复杂图表智能体实现.....	14
4.5 预期目标.....	14
第 5 章 已完成工作与进度安排.....	15
5.1 已完成工作的初步积累.....	15
5.2 进度安排.....	20
第 6 章 所需条件和预期挑战.....	21
6.1 所需的条件以及经费.....	21
6.2 预期困难和解决方案.....	21
参考文献.....	23

第1章 选题背景与研究意义

1.1 研究背景

大数据时代，数据已经成为生产决策中不可或缺的元素。随着互联网的普及，数据的规模和复杂度逐年上升，然而，我们有效理解数据的能力并没有同步增长，有限的认知能力不足以分析高维、动态和噪声密集的数据。在这一背景下，可视分析作为理解数据的一种方式，是通过交互式可视化界面促进分析推理的科学^[1]。其核心价值不在于静态地展示数据，而在于通过处理复杂、模糊的数据并将其可视化，让用户通过视觉形式，感知和理解数据内在模式和异常，提高决策的质量。



图 1-1 交互式可视化图表示例：基础折线图，凹凸图，堆叠面积图，北京 AQI 可视化，基础柱状图，瀑布图，堆叠柱状图，多数据柱状图，环形图，圆角环形图，联动和数据图，全国宏观经济指标分析图，基础散点图，单轴散点图，多数据散点图，热力图

交互式可视化图表不只是一个静态的数据展示工具，它能让用户与数据互动，这种互动包括点击，滑动，缩放，过滤，使数据展示变得更加生动和有趣，如图1-1所示。通过这种互动，用户可以更加深入地探索数据，发现隐藏在数据背后的信息。

但是，工具种类的丰富以及工具设计的复杂度提升，使得用户被大量的界面配置信息和参数设置所困扰。

多模态大语言模型的发展为交互式可视分析提供了一个新的可能：模型可以学习大量的交互式可视化图表的元操作，存储为知识库。根据当前交互式可视化系统的截图或者介绍，通过文本推理，理解当前系统支持的交互操作。大模型具备以下能力：将用户指令分解为当前可视化系统支持的原子操作，并调用函数精准执行，然后通过回环验证提升准确度。当这些能力被引入可视分析场景时，理论上可以将用户从复杂的界面设置和繁琐的操作链条中解脱出来，使得用户可以更多地关注问题建模，更准确和显示的问题表达，从而帮助用户给出更高质量的决策。

1.2 研究意义

尽管应用前景广阔，但现有的多模态技术在实际可视分析场景中仍面临诸多挑战。首先，面对模糊的用户意图，大模型难以将其转化为有效的原子操作；其次，针对明确的用户指令，模型规划的子任务可能超出当前系统的支持能力。此外，子任务的执行精度往往不足。交互式分析本质上是一个多步、长程的决策过程，任何早期误差都可能在后续步骤中被不断放大，最终触发级联失效。

本研究旨在构建面向可视化交互界面的 GUI 智能体。首先，构建一套标准化的评估体系和评测基准，以量化大模型在现有交互式可视化系统中的能力边界。然后，构建智能体，可以将用户指令分解成有效原子操作，增强原子操作的执行能力，进而提高智能体在简单图表的推理和问答的能力，在复杂图表的理解能力。

第2章 国内外研究现状

本章将系统梳理与本研究密切相关的四个核心领域：大模型辅助的可视化（LLM4VIS）、图表视觉问答（Chart VQA）、图形用户界面智能体（GUI Agents）以及多智能体协同推理（Multi-Agent Systems）。通过回顾这些技术的发展和主要工作，明确本研究的切入点，从对静态可视化图表的生成或者推理转向对交互式可视化图表的动态推理。

2.1 机器学习辅助可视化

随着人工智能技术从判别式转向生成式，大模型辅助可视化的研究，从传统的启发式规则推荐，转向基于通用大语言模型的端到端语义映射。这个领域主要围绕可视化生成、可视化理解以及可视化评估三个维度展开，旨在利用大模型强大的认知和推理能力降低数据可视化的创建与解读门槛，并为构建具备高可视素养的智能体提供理论基石。

在可视化生成维度（NL2VIS），为了解决如何解决从抽象数据到具象视觉编码的冷启动问题^[2]，一些工作利用大模型语义理解和代码生成的能力，将自然语言意图转化为可执行的可视化规范。例如，Tian 等人提出的 ChartGPT^[3] 与 Wang 等人的 DracoGPT^[4]，通过利用可视化领域的抽象语句和图表数据进行微调，使模型能够捕捉人类的设计偏好并将自然语言查询转化为声明式规范。此外，为了提升生成结果的可解释性与美学质量，Wang 等人的 LLM4Vis^[5] 与 Zhang 等人的 AdaVis^[6] 引入了基于推理链的推荐机制，确保生成的图表不仅语法正确，且符合设计美学。尽管生成式模型极大提升了生产效率，但其输出往往是静态的、一次性的。这种模式，限制了大模型生成的可视化图表，在动态探索场景中的应用。

在可视化理解维度，赋予机器类似人类的读图能力，是构成 GUI 智能体感知环境的基础。Dong^[7] 等人与 Hong^[8] 等人通过构建大规模基准测试，系统性地探究了当前视觉语言模型的可视化素养。研究发现，虽然模型在通用语义理解上表现出色，但在面对需要精确数值推理或布局泛化的任务时仍存在显著的感知缺陷。为弥补这一短板，Zeng^[9] 等人提出了基于可视化参考的指令微调策略，显著增强了多模态模型在图表问答中的鲁棒性。同时，为了深入解析图表的内部结构，Chen 等人的 VisAnatomy^[10] 与 Liu 等人的 SimVecVis^[11] 构建了包含细粒度语义标签的数据集，试图增强模型对图表组件（如坐标轴、图例、数据标记）的解析能力。

在可视化评估维度，研究焦点在于利用大模型作为批评家来审视可视化质量，这与本研究提出的架构高度契合。Chen 等人的 VisEval^[12] 的工作表明，大模型具备识别误导性可视化与评估设计质量的潜力，具体而言，LLM 具备发现一些明显的错误，如坐标轴未标记这类错误，但其在深度逻辑上仍有不足。Shin 等人的 Visualization^[13] 进一步将这种能力产品化，他们构建了一个基于 LLM 的设计反馈系统，能自动告诉设计师图表哪里画得不好，实现了自动化的交互式可视化设计的反馈闭环。然而，Shao 等人^[14] 与 Wang 等人^[15] 的研究也警示，大模型的评估偏好与人类专家之间仍存在不同的标准，特别是在涉及复杂上下文推理时，机器的打分往往过度自信。这也暗示了在智能体架构中引入验证机制的必要性。

大模型辅助的可视化，在静态图表的生成和理解 and 评估上取得了长足进步，但呈现出碎片化特征：生成模型不懂感知，理解模型无法操作，评估模型缺乏介入手段。大多数工作如 LEVA^[16] 和 ChartGalaxy^[17] 仍停留在静态问答或单轮生成，尚未触及动态交互这一可视分析范围。

2.2 图表视觉问答

图表视觉问答，聚焦于大模型对静态图表的感知与推理能力，即让智能体能够看懂图表并且回答关于数值检索，趋势判断，或者数据关系推理的问题^[18]，这是衡量智能体读图水平与视觉逻辑推理能力的核心基准。

技术路线上，该领域正经历从光学字符识别逆向工程向端到端多模态推理的转变^[19]。传统的解决方案主要采用先从图表空间转换到文本控件，然后推理的策略。这种方法试图将位图反向还原为底层的结构化数据，再利用大语言模型进行文本推理。然而，这种方法存在着明显的核心缺陷：它严重依赖字符识别的准确性与图表的规范性。在面对无文本标注、手绘风格或高度抽象的复杂图表时，由于无法提取有效文本，整个推理链路会瞬间崩塌，导致级联失效^[20]。

相比之下，随着新一代多模态大模型的出现，基于视觉变换器的端到端视觉推理逐渐成为主流。这类模型直接将图像作为输入，通过编码器提取视觉特征，并在隐空间中与文本特征进行多模态对齐^[21-22]。虽然这种方法具备更强的适应性，能够捕捉全局的视觉模式，但在处理需要极高精度的数值读取任务时，仍面临能否在图像空间准确感知的挑战。

针对这一问题，ChartAgent^[23] 没有只是依靠多模态大模型内部的隐式思维链，因为隐式思维链在处理精细图表时，缺乏空间感知的精确度。ChartAgent 提出了一套图表专用视觉工具箱，通过代码调用来辅助视觉感知。具体而言，它利用智能裁剪工具将包含多个子图的面板进行分割，减少背景噪声干扰；利用辅助线绘

制在视觉上连接数据点与坐标轴，显著降低了模型读取数值的估算误差^[24-25]。在 ChartX^[26] 等高难度基准测试中，这种显式的视觉增强策略证明了极高的投入产出比。

尽管 ChartAgent 引入了操作图像的工具箱，包含 16 个图像推理工具，但其操作对象仍是静态的图像文件，而非具备动态的交互式能力的可视化界面。它可以在图片上进行画线，裁剪，分割图元等操作，但无法触发交互式可视化图表中的悬浮提示、高亮或动态重绘效果。这意味着它无法获取那些仅在交互后才显示的按需展示的数据。这是从静态读图迈向动态交互的关键转变，也是本研究的的重点。

2.3 图形用户界面智能体

本研究中的图形用户界面智能体是指能够模拟人类用键盘和鼠标操作数字界面的智能体。这一领域是让 AI 模型通过对用户指令的分解和对当前截图的推理和视觉问答，顺利完成点击、输入、滚动、拖拽等操作技能。当前主流架构是感知-探索-规划-行动的闭环模式^[19,27]。代表性工作如 AppAgent^[28] 等，通过在大规模界面截图与操作轨迹数据集，如 Mind2Web^[29] 在 OSWorld 上^[30] 上进行预训练，赋予了智能体不依赖底层代码，仅凭视觉信息即可操作任意软件的通用能力。技术上，它们通常采用定位模型，将屏幕截图作为输入，输出图表的结构化描述或直接预测坐标。

2.3.1 感知：从像素到图像语义的映射

感知阶段是为了让智能体理解屏幕内容。对于图表而言，难点在于如何从非结构化的像素中提取结构化的数据信息。早期的 GUI 智能体依赖于文档对象模型 (DOM) 或无障碍树的解析^[19]。然而，随着 Canvas/SVG 等渲染技术在主流的可视化工具，如 Tableau^[31], PowerBI^[32], ECharts^[33] 的普及，DOM 结构日益扁平化或仅仅是一个容器，智能体无法通过 DOM 树获取具体的柱状图高度或散点坐标信息。这促使技术路线转向基于视觉的感知，如截图等。

第一类是多模态视觉感知，这是当前的主流方向。智能体直接像人类一样处理屏幕截图。利用 GPT-4V^[34]、CogAgent^[35] 等多模态大模型，智能体可以直接理解视觉元素。在图表场景中，这使得智能体能够看到图表的趋势、颜色和形状。CogAgent 等模型通过高分辨率处理，专门优化了对细小元素，如小图标、密集数据点的识别能力。

第二类是工具增强感知。为了解决大模型看不清微小图表元素的问题，引入了辅助工具，例如 Set-of-Mark^[36] 和 OmniParser^[37] 等。在图表场景中，这些工具可

以先运行一个目标检测算法，给屏幕上的每一个数据点或图例打上数字标签，即 Bounding Box，然后再把带标签的图喂给大模型。这极大地提高了智能体在密集散点图或复杂仪表盘定位元素的精度^[19]。

2.3.2 探索：构建可视化工具的知识库

面对一个陌生的交互式可视化界面，智能体需要通过探索来习得如何操作它，从而构建针对当前界面的知识库。探索的模式可以分为内部探索，外部探索和历史经验利用这三种。

内部探索是指智能体通过随机或任务驱动的方式与界面互动，观察界面反馈^[19]，从而理解 UI 元素的功能。在图表场景中，这对应于智能体尝试点击图例观察过滤效果，或悬浮在数据点上触发 Tooltip，从而习得特定交互逻辑。

外部探索是指智能体利用搜索引擎或查阅官方文档，如 API 文档、软件手册、使用手册或者论文介绍来获取操作知识。例如，AssistGUI^[38] 通过检索外部教程来辅助决策。在图表场景中，当智能体不知道如何在复杂图符这种交互式可视化场景中有哪些交互操作，图元的含义什么，它可以检索外部知识库，将检索到的内容转化为自己的操作指南和储备知识库。

历史经验利用是指记录过去成功的操作轨迹，形成技能库。Synapse^[39] 和 MemoryBank^[40] 等研究展示了如何通过检索历史成功的案例来指导当前任务。在图表场景中，智能体可将成功操作链存储起来，下次先进行图表类型和任务的匹配，进行少样本提示或者上下文学习。

2.3.3 规划：复杂可视分析任务的分解

可视分析任务通常是抽象且长程的，例如分析为什么 Q3 利润下降，规划模块负责将其拆解为当前交互式可视化界面支持的具体的执行步骤。推理框架分为 Chain-of-Thought (CoT)^[41] 和 ReAct^[42] 两种。CoT 是指让智能体一步步思考。针对图表场景，例如，CogAgent^[35] 和 MM-ReAct^[43] 将 CoT 扩展为多模态版本，即结合屏幕截图的视觉特征进行联合推理。而 ReAct^[42] 是图表交互最常用的模式，即观察-思考-行动循环。例如在 Mind2Web^[29] 等通用网页智能体中，这种模式被广泛用于处理多步交互任务。

2.3.4 行动：超高精度的可视界面操控

行动或者交互环节，是智能体将规划转化为实际鼠标或者键盘事件的环节，在本研究中是利用 pyautogui 这一 Python 库进行模拟，可以模拟人类进行点击、拖拽、悬浮、输入文本、缩放等操作。在交互式可视化场景中，这对精度要求很高。

界面定位是行动的核心，即将点击某个折线图中的某某点这样的语义指令，转化为屏幕上的横坐标和纵坐标。针对这一挑战，SeeClick^[44] 提出了专门针对 GUI 元素的定位预训练模型。图表场景的特殊挑战在于，数据点往往只有 3-5 个像素，且密集排列。通用模型极易出现点击漂移，导致误触相邻数据点^[45]。为了将自然语言指令映射为屏幕像素坐标，通过在输入图像中加入坐标轴、网格、带标签网格等明确的视觉信息提示^[46]，让 VLMs 能够展现其隐含的空间理解能力。

基于规划生成具体的动作序列。在图表交互中，智能体不仅要生成动作类型，还要精确计算动作的参数，如拖拽的起始和终止坐标。操作后，智能体必须进行自我反思，例如检查图表是否真的更新了。

2.4 多智能体系统与协同推理

面对单个智能体在长程任务中的认知过载和幻觉问题，多智能体协作已成为解决复杂推理任务的标准范式^[47-48]。通过角色分工，不同的智能体可以专注于任务的不同方面，从而提升整体系统的鲁棒性。现有的多智能体系统主要呈现出辩论与角色扮演两种主流方法。

早期的多智能体研究多采用辩论范式，通过多个同质或异质智能体之间的多轮对话、辩论与投票来提升推理质量。代表性工作如 ReConcile^[49] 与 Multi-Agent Debate^[50] 机制，让智能体独立生成解决方案并相互提问解答，通过聚合多视角信息来修正个体的认知偏差^[12]。

然而，单纯的辩论可能导致对话发散，且难以通过协商解决。结构化更强的角色扮演方法，依据标准作业程序将复杂任务解构，并分配给规划者、执行者、代码专家等专用角色^[51]。这种各司其职的架构不仅显著提升了任务执行的专业度，还为引入领域特定的外部工具提供了标准化的接口。

借助视觉推理领域的工具增强，多智能体系统的能力边界也在不断拓展。早期的工具增强方法如 MM-REACT^[43] 与 ViperGPT^[52]，主要通过生成 Python 脚本来编排视觉模型或执行逻辑查询，其输出仍局限于文本或代码模态。为了处理更复杂的视觉任务，近期的研究开始强调中间视觉证据的生成。典型的如 Set-of-Mark 技术^[36]在图像上叠加显式的语义标记，为智能体提供了一套显示的清晰的视觉词汇表，从而显著提升了其在视觉定位与物体检测中的精度。

传统的推理-行动范式虽然在文本推理中表现优异，但在处理高维视觉信息时，可能因上下文过长而遗忘视觉细节，导致推理链断裂。PixelCraft^[53] 为结构化图像的推理任务提供了一种高效的调度器-规划器-批评家协作架构，这里的结构化图像包括可视化图表，几何图表，文档的截图。PixelCraft 引入了图像记忆与非线性回

溯机制。不同于传统线性思维链，仅存储文本步骤或者存储所有图片或者只存储最近一张图片，他们的规划器维护了一个全局的视觉状态库，只存储对的图片和文字描述。这使得系统具备了非线性回溯能力：当发现当前的推理路径走进死胡同，智能体可以调取多步之前的视觉快照，重新规划。此外，视觉批评家的引入构建了基于视觉的反馈循环，负责在每一步执行后，对比期望结果与实际视觉状态，显著降低了执行过程中的累积误差^[54]。

PixelCraft的成功为本研究提出的 VAST-Agent 提供了可参考的方案。PixelCraft 主要关注静态图像的处理，本研究将把 PixelCraft 的做法迁移到动态的交互式可视化图表场景中：一方面，将图像记忆扩展为交互历史记忆，记录界面变化与操作日志；另一方面，借鉴视觉批评家的做法，新增交互批评家，专门用于在检测智能体完成的交互操作是否正确触发了界面的状态变化，正确的状态变化是子任务中是有语言描述的。

通过对上述四个领域的调研，可以看到当前技术格局：NL2VIS 擅长生成，但缺失交互^[2]；Chart VQA 擅长理解静态图，但无法操作动态界面^[23]；通用 GUI Agent 擅长点击按钮，但是难以精准操作图表^[28]；而 PixelCraft 提供了协作架构，但尚未涉足动态可视分析^[53]。

本研究提出的 VAST-Agent 试图在视觉感知与动态交互之间构建一座桥梁。当大模型拥有了像人类分析师一样的手和眼后，多模态大语言模型在交互式可视分析中如何应用？本研究将融合 ChartAgent 的视觉增强工具箱、GUI Agents 的通用操作能力以及 PixelCraft 的多智能体协作架构，构建一个既懂数据语义、又能精准操作交互式可视化图表，同时也具备自我纠错能力的智能体。下表直观地对比了现有主流技术与本研究（VAST-Agent）在核心能力上的差异：

表 2-1 现有技术与 VAST-Agent 核心能力对比

维度	NL2VIS	Chart VQA	通用 GUI Agent	VAST-Agent
交互范式	静态生成	静态位图操作	通用导航截图	动态图表交互
感知模式	开环无反馈	单帧静态	UI 控件反馈	主动变焦闭环
验证机制	无	视觉工具校验	简单执行校验	视觉差异校验
语义理解	语法驱动	视觉特征驱动	DOM 结构驱动	数据映射驱动
长程鲁棒性	低	中	中	高

第3章 研究内容

3.1 构建交互式可视图表的评估基准

目前主流的多模态大模型评测集（如 ChartQA^[18], ChartQApro^[55], ChartXiv^[56], ChartBench^[57], ChartX^[26], InfoChartQA^[58], EvoChart^[59]等）

多聚焦于静态图表的问答，缺乏对动态交互过程的考量，如图3-1所示。本研究旨在填补这一空白，将构建首个面向交互式可视分析环境的标准化评估基准（InterVis-Bench），可以量化智能体在复杂动态环境中的感知-探索-规划-行动的闭环能力提供支撑。




图 3-1 EvoChart-QA benchmark^[59], ChartQA benchmark^[18], ChartX benchmark^[26]的对比图

作为研究的基础，首先需要构建一套标准化的评估体系，以量化大模型在现有交互式可视化系统中的能力边界。该基准主要包含两个维度的测评：首先，是用户意图理解能力与任务规划能力的测评。重点考察大模型能否精准解析当前界面的视觉状态与元数据，通过截图的形式提供给多模态大模型，并结合系统支持的交互动作，将模糊的用户指令拆解为可执行的原子操作序列。这要求模型不仅能理解图表语义，还能正确推导达成目标所需的逻辑步骤。

其次，是原子操作的执行能力测评。对于规划的子任务，进一步评估模型在交互式可视化系统中执行的准确性。测评范围覆盖两个层次，第一是基础视觉感知，包括识别图例颜色、读取坐标轴数值等；第二是交互执行与反馈处理，包括点击特

定数据点、操作滑动条、设定筛选条件，以及准确读取弹窗中展示的数值。

最终，本研究将构建一个涵盖多类图表与多级任务难度的评估基准，为后续智能体的构建提供评测数据支撑。同时，在下一步的智能体构建中，会针对评估基准中失败案例，做针对性的优化。

3.2 面向简单通用图表的 GUI Agent

基于上文评估基准中所展示的问题，本节旨在构建面向通用标准的交互式可视化图表，如折线图、柱状图、雷达图等 GUI 智能体。通过交互方式，解决视觉遮挡与数据密集场景下的感知难题。

现有研究??表明，单纯依赖单帧静态的截图，当处理高密度数据时，智能体预测的精度难以达到用户的预期。例如，当折线图中包含多条交织的曲线或散点图中存在大量重叠点时，模型往往难以区分不同的数据系列，导致推理错误。同时，在获取图表中的某一个元素的数值时，现有解决方案仅凭像素相对位置估算数值，其精度在一定程度上无法满足可视分析需求。

针对上述问题，本研究所提出的智能体不仅可以被动接收静态图像，还可以通过主动交互来获取更多信息。具体而言，智能体可以通过筛选操作减少视觉干扰，通过缩放分离重叠数据点等方法，显著降低大模型的识别负担。除此之外，智能体可以通过悬停点击触发弹窗，直接读取精确数值，将复杂的视觉推理任务转化为简单的文本阅读任务，显著降低推理负荷。通过这些交互操作，可以提升在交互式可视分析场景下任务的完成率与数据的准确性。

3.3 面对复杂专用图表的 GUI agent

在解决通用图表的基础上，本研究将进一步扩展智能体的能力边界，使其能够理解复杂的自定义图表与多视图系统。

首先，针对交互式系统中常见的非标准化、相互嵌套的自定义图符，本研究将解决因缺乏通用视觉特征导致的语义解析难题。研究将利用大语言模型的长文本理解能力，通过注入图符定义、图例说明或设计文档，使智能体能够通过上下文学习掌握特定图表的视觉编码规则及交互逻辑，从而有针对性的解析这类自定义的交互式可视化图表，并将用户指令映射为符合该设计中包含的原子操作。

其次，针对交互式可视化中的多视图协调问题，即多个视图间存在联动关系，本研究将探索具备全局上下文感知能力的智能体架构。通过维护全局状态记忆，智能体将学习如何在不同视图间进行跨组件的交互操作与推理，综合主视图与从视

图的信息来完成长程推理和交互，进而达到用户的预期功能。

第 4 章 研究方案及预期目标

4.1 总体方案

本研究首先基于 Web 可视化技术构建仿真环境与评测体系，对于每一个交互式可视化图表，提出的问题通常需要多步交互，才能找到问题的答案，而不是对前一张截图进行反复推理；随后基于 React 框架开发智能体，依次解决通用图表的主动感知与复杂图表的协同推理问题。该智能体能够对全局截图提取图表元数据，同时，针对数据密集区域或者自定义图符等其他情况，能够触发当前界面支持的交互操作。

4.2 任务一：InterVis-Bench 基准构建

针对任务一，本研究将构建一套标准化的评估体系，以量化大模型在现有交互式可视化系统中的能力边界。首先是环境搭建与数据生成。利用 ECharts^[33] 和 Vega-Lite^[60] 等交互式可视化资源库，程序化生成交互式可视化图表的界面，涵盖柱状图，折线图，饼图，散点图，K 线图，雷达图，热力图，数图，旭日图，地图，线图，关系图，箱线图，平行坐标图，仪表盘图，漏斗图，桑基图，主题河流图，象形主图等共计 500 个以上的交互式图表页面。为了保证数据的多样性，将对数据分布、图表样式、交互组件进行参数化配置。对于复杂场景，将构建包含多视图联动和参照可视化论文中提供的图符案例。

其次是指令集与真值构建。采用逆向的方式构建用户指令集。基于图表的底层元数据，如 JSON，结合当前交互式可视化界面支持的控件，具备的功能，以及初始界面的状态或者当前截图展示的界面状态，利用 GPT-4 生成对应的用户意图，涵盖数值查询和对比，因果分析，决策建议等。同时，大语言模型还需要生成标准操作序列。为了量化评估，系统将在渲染层注入探针代码，实时记录 DOM 状态变化、Tooltip 文本内容以及鼠标点击坐标，以此作为自动化评分的客观依据。

最后是评估指标设计。除了常规的任务成功率，本研究将进一步评估模型在执行层面的准确性。测评范围涵盖三个层次：第一是基础视觉感知，这是考察模型对图例颜色识别、坐标轴数值读取、图元几何位置定位的像素级精度等。对于前两项指标，可以用 True 或者 False 给一个标记，对于最后一项，可以计算点击坐标与目标图元中心的欧氏距离作为感知误差；第二项是交互动作的分解能力，这里是考察模型能否结合用户需求和当前可视化界面支持的原子任务正确的到子任

务，例如，执行点击或悬浮在给定横坐标纵坐标的数据点、拖拽滑动条至指定范围、设定复杂的组合筛选条件等操作。在能够正确达到用户需求的前提下，可以设计交互效率这一指标，通过计算智能体操作步数与最优路径的比值得到；第三项是动态反馈处理，考察模型在执行操作后，能否观测到交互界面的前后变化情况，比如看到某类数据已经被隐藏，指令中要求的目标被放大，读取图表中弹窗中展示的数值信息，并根据结合用户指令，当前子任务以及系统支持的交互动作，评估当前子任务的完成情况，推理出下一步要做什么：是继续下一个子任务，还是调整下一个子任务。

最终，本研究将基于上述指标，构建一个包含多种类别的通用图表与专用图表、覆盖多级任务难度的用户指令的综合评估基准。该基准不仅为后续智能体的构建提供数据支撑，还将通过对失败案例的分析，有针对性的指导后续智能体的迭代优化。

4.3 任务二：通用图表智能体实现

针对任务二，本研究将设计感知-规划-行动三位一体的智能体架构，重点是感知和交互技术的实现。

在感知层，采用从粗到细的视觉策略。智能体首先利用多模态大语言模型对当前交互式可视化界面全屏截图进行信息提取，这些信息包括子图个数，每一个子图的类型，子图的名称，子图的图例，每一个子图的 X 轴和 Y 轴标签，每一个子图的 X 轴和 Y 轴 Tick 数据，整个系统支持的交互操作，每一个子图支持的交互操作，识别全屏截图中的所有交互控件并与前面的内容进行对照。结合用户查询和分解后的子任务，多模态大模型推理到和完成用户指令相关的图像区域，设计动态变焦的方法，当检测到数据点重叠率超过一定阈值时，会优先把局部放大操作加入子任务序列方便后期获取高分辨率视图区域进行任务完成。

在交互层，除了调用 Python 库的方式模拟人的交互操作，例如顺利完成点击、输入、滚动、拖拽等操作技能。还需要实现基于 OCR 的弹窗读取机制。智能体将可以先控制鼠标悬停或这点击在目标位置，截取即时屏幕，利用轻量级 OCR 模型提取弹窗内的文本数值。若未检测到弹窗，系统将触发位置微调，调用视觉大模型推理新的横坐标纵坐标位置或者推理相对位置，在目标坐标周围 3-5 像素范围内进行探索性悬停或者点击，直至获取有效反馈。

4.4 任务三：复杂图表智能体实现

针对任务三，本研究将引入知识增强与全局状态管理机制。针对自定义交互式可视化图表，如图符，采用检索增强生成与上下文学习相结合的方案。构建一个包含常见可视化设计规范的数据库。当智能体遇到陌生图符时，首先根据多模态大模型提取元数据中包含的描述检索相似的图例说明或 API 文档，将其作为提示词的前置上下文输入大模型，辅助模型建立视觉特征和数据含义的映射关系，或者直接向大模型提供图符的设计方案，或者图符对应的可视化论文。

针对多视图联动，设计全局工作记忆模块。该模块维护一个状态树，实时记录各个视图的筛选状态，如时间轴已选 2023 年、地图已选北京市。规划器在生成动作前，需查询全局状态树，确保当前操作不会与已有筛选条件冲突，并能利用视图间的联动效应来获取隐藏信息。

4.5 预期目标

本研究预期达成以下四项具体目标。首先，发布 InterVis-Bench 评测基准，包含超过五百组动态交互测试样本及配套的自动化评测脚本，填补交互式可视分析评测领域的空白。其次，完成 VAST-Agent 原型系统的开发，实现智能体的基本功能，能够根据交互式可视化系统完成可视分析任务。进而，在性能指标上，预期在 InterVis-Bench 的高难度复杂任务中，相比零样本或者少样本提示基线，将成功率提升，并将平均像素误差控制在一定误差以内。最后，基于上述研究成果完成硕士学位论文，并力争在可视化或人工智能领域的会议发表一篇学术论文。

第 5 章 已完成工作与进度安排

5.1 已完成工作的初步积累

首先，在文献综述与问题定义阶段，梳理了国内外关于多模态大模型在图表理解及 GUI 智能体领域的研究现状，通过对比分析，明确了本文研究聚焦于交互式可视化图表这一动态交互场景。其次，在工程基础与仿真环境建设层面，本研究基于 Python 换镜，通过调用 API 获取大语言模型或者多模态大模型的能力。系统采用 Streamlit 框架构建交互式环境，通过 ECharts 动态渲染具备交互功能的可视化图表。同时，为了多模态大模型根据裁剪后的 patch 推理出来的坐标与实际坐标对齐的问题，利用 mss 与 pygetwindow 库实现了针对特定应用窗口的高清图像采集，并结合中间推理信息，调用程序代码进行计算。利用 pyautogui 实现了基于屏幕绝对坐标的精准交互，包括鼠标移动，点击，拖拽，键盘输入，组合键功能。

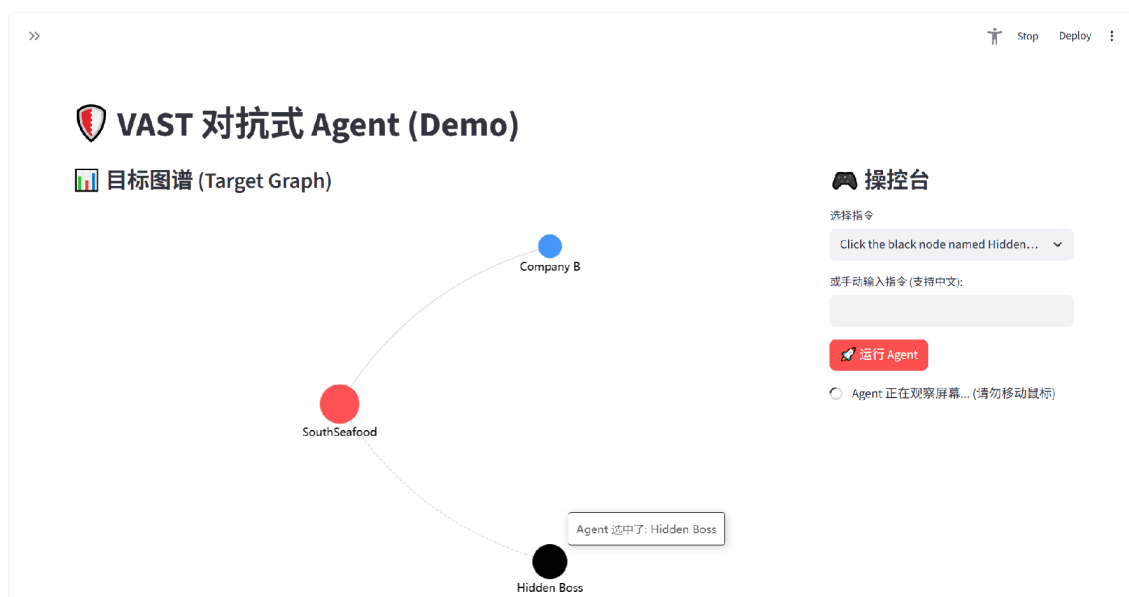


图 5-1 案例一提供了包含三个节点的交互式可视化图表，当鼠标点击节点时，会有弹窗

第一个小的案例提供了包含三个节点的交互式可视化图，三个节点分别是 SouthSeafood，Company B 和 Hidden Boss，这三个圆的直径分别是 50,30,40 像素大小。当鼠标点击节点时，会有一个弹窗展示相关信息，如 5-1 所示。

用户指令是，“Click the red node named SouthSeafood”，“Click the black node named Hidden Boss”，“Click the blue node Company B”。通过这个案例，可以验证调用 gemini2.5Pro 的 API，可以通过闭环验证和反馈机制，实现对图形用户界面的




图 5-2 案例一中每一步划分网格和验证信息的详细过层程示意图

感知和定位。可以看到，通过划分网格和选择网格，如图5-2所示，让 Gemini 2.5 Pro 预测 bounding box 的方式，可以较为准确的点击到三个节点的中心位置，如图5-3所示。此外，这个案例使用的网格标签在截图四周以外，即在新增的 padding 区域中。区别于论文??中的将网格标记叠加在截图上的做法，因为当裁剪到第三轮第四轮的时候，强行叠加网格会引入视觉干扰，如图5-4所示。




图 5-3 案例一点击三个节点的最终效果展示，蓝色点的位置是模型预测的结果，绿色框线是预测的 BBox



图 5-4 案例一在裁剪到第三轮第四轮的中间视觉信息，表明强行叠加网格会引入视觉干扰

在每一轮定位迭代中，系统将带有网格的图像输入 Gemini 2.5 Pro 模型。模型根据用户指令返回目标的归一化检测框及思考过程。通过计算交并比和中心偏移量来实时评估定位精度。若目标在视野中的占比或居中程度未达到预设阈值，系统将以当前预测的中心点为原点进行局部裁剪，并进入下一轮精细化检测，如划分网格所示。

在完成多轮裁剪和多轮预测后，会得到最终预测到的要点击的横坐标和纵坐标，随后进入坐标还原与动作执行阶段。由于模型返回的坐标是基于裁剪后的局部图像，设计了一套多级坐标变换逻辑。该逻辑通过累加每一轮迭代产生的全局偏移量，并扣除绘图产生的补白区域，将局部归一化坐标准确映射为操作系统的全局物理坐标。最后，系统通过 pygetwindow 库实现了对特定窗口的动态锁定与激活，确保了在多任务环境下操作的准确性。

第二个小的案例，提供的是一个折线图，如图5-5所示，包含 Email, Union Ads 和 Video Ads 三条折线，用户指令是”Click the point for Wednesday, Email”, ”Click




图 5-5 第二个案例的初始状态示意图

the point for Friday, Video Ads”, ”Click the point for Monday, Union Ads” 这些。其中，三个图例是可以隐藏的。当鼠标单击折线上的具体点的时候，会有弹窗提示当前点具体的信息，包括类别、时间和数值等。

这个小案例采用了分层推理架构，将任务分解为不同复杂度的子任务，并分配给不同特性的模型。Fast 模型主要负责任务规划，利用其响应速度快的特点进行初步定位；而 Smart 模型则扮演裁判的角色，负责对候选区域进行视觉审核、图例解析以及最终的精准点击点决策。

同时，初步想用自适应标尺网格，即根据当前视野的分辨率，动态调整网格的密度（如 4x4 或 6x6 或者 9x9），希望能找到合适的网格划分方式，提取到包含回答子任务的最合适的 patch。同时，标尺置于图像边缘，在不干扰模型视觉特征提取的前提下提供空间坐标参考。这个小案例采用丰富的评估与回溯机制，即在每一层缩放过程中，系统会进行视觉合法性检查。如果当前裁剪区域被判定为不包含目标或出现偏差，系统会触发回溯逻辑，转向备选的网格单元进行搜索。这确保了智能体在面对相似图标干扰时具有自我纠错能力。因为在前期很小的视觉感知偏差，会在后面引起误差的级联放大。




图 5-6 第二个案例中锚点定位的中间视觉信息展示

为了实现对图表数据点的精准定位，案例将定位这个任务分解成两个阶段完成，第一阶段是锚点定位，这里的锚点指的是横坐标的某个刻度线在当前截图的




图 5-7 案例二的效果示例 1，交点预测的效果，紫色点的位置是模型预测的结果，绿色框线是局部放大图

X 值，或者纵坐标某一刻度线在当前截图的 Y 值，在这个例子中是负责在坐标轴上寻找对应的标签，如 **Wednesday**，如图5-6所示。通过严格的刻度检查，模型被要求优先长处理刻度线而非文字中心，从而获得基准坐标。

第二阶段是交点预测，代码会根据第一阶段得到的锚点位置，绘制一条引导线。随后，智能体需在引导线与特定颜色序列的交汇处进行交点坐标预测，为了防止模型误触图例或背景杂色，系统在 **Prompt** 中嵌入了颜色强校验和干扰排除规则。最后，代码通过计算会给出鼠标需要移动到哪里进行什么类别的交互操作。从图5-7 可以看到，模型能够较为准确的点击到折线图上对应的点位。




图 5-8 案例二的效果示例 2：灰色点的位置是模型预测的结果，绿色框线是局部放大图

可是由于大模型的不稳定性，从图5-8中可以看到，即使在相同的代码中，并

且锚点预测的位置相差不大，多模态大模型对于交点预测任务也会出现较大的偏差，这进一步说明了多重验证机制的重要性。更进一步，如果第一阶段的锚点定位出现偏差，其误差会在第二阶段级联放大，导致点击位置与目标点相差甚远，如图5-9所示。




图 5-9 案例二的效果示例 3：灰色点的位置是模型预测的结果，绿色框线是局部放大图

5.2 进度安排

根据本课题的研究目标与技术路线，结合已有的工作基础，制定了涵盖基准构建、算法攻关、系统集成与论文撰写的进度安排。具体时间节点规划如下表所示：

表 5-1 硕士学位论文研究工作进度安排

时间段	任务安排
2024.09 - 2025.01	初期探索与技术储备（已完成）：完成相关领域文献的深度调研，确立智能体核心架构；完成智能体开发环境的搭建与技术验证。
2025.02 - 2025.04	基准构建与数据选择：开发自动化交互式图表生成引擎，构建 InterVis-Bench 评测基准；开发半自动标注工具，完成指令和轨迹对齐的高质量标注，并确立指定的真值。
2025.05 - 2025.08	核心算法攻关与原型实现：重点完成主动变焦方法与几何约束机制；在简单任务上跑通端到端可视分析过程。
2025.09 - 2025.12	全面评估与系统优化：在 InterVis-Bench 上进行评估；通过消融实验验证各模块贡献；针对长程任务中的级联失效问题进行针对性优化。
2026.01 - 2026.05	论文撰写：整理实验数据与代码文档，撰写高水平学术小论文并投稿；完成硕士学位论文的撰写、修改与定稿，准备答辩。

第 6 章 所需条件和预期挑战

6.1 所需的条件以及经费

为顺利完成本研究构建的智能体框架，需要依托高性能计算资源与多模态大模型接口的双重支持。在算力资源方面，由于视觉感知涉及锚点、数据轴的刻度线等视觉信息的推理，以及可能涉及的本地多模态模型的微调实验，需要实验室提供配备英伟达图形处理器服务器集群以保障实验效率。在模型服务方面，本研究的核心推理依赖于 GPT-5.2 或 Gemini 3 Pro 等闭源大模型的应用程序接口，这需要持续的科研经费支持以覆盖高频次调用的成本。此外，本研所在课题组在交互式可视分析与人机交互领域积累了深厚的学术底蕴，导师与同门在图表生成逻辑、交互范式设计等方面的经验将为本研究提供重要的理论指导；同时，课题组现有的可视化代码库也将降低系统的成本。综上所述，依托课题组现有的软硬件基础设施与学术环境，本研究具备了坚实的可行性基础。

6.2 预期困难和解决方案

在实现智能体感知-探索-规划-行动的闭环的过程中，预计会面临以下两个主要挑战，这一小节提出了可能的解决方案。首先是多模态大语言模型预测坐标的精度不足，大模型内部存在的幻觉导致难以直接输出像素级别的精确坐标，但是在交互式可视化图表中的交互操作，通常需要非常高的精度，否则会导致操作失败。针对这个问题，一个可能的解决方案是引入几何约束机制，比如当发现回答问题的元素在当前 patch 的边缘或者在轴上时，要求重新划分网格。更进一步，对于 patch 中的求解交点的问题，可以先找到最干净的 patch，识别出单一线条的坐标，然后通过数学计算的方式，推导出交点的坐标，而不是直接让大模型预测交点坐标，完成这个功能是在对简单的视觉线条的推理以及精确识别单一点的坐标上。另一个可能的解决方案是，参考人类操作交互式可视化界面的方式，虽然多模态大语言模型预测的坐标不够精准，但是可以引导智能体在预测坐标附近进行小范围的探索性点击，直到获得正确的反馈为止，也可以通过截取附近的区域，如 30 像素的圆，进行多次预测，取平均值的方式来提升坐标的精度。

其次是多步推理中的误差级联风险。在完成复杂可视分析的任务中，智能体需要执行长达数步的操作序列。一旦早期的根据用户指令进行的子任务拆解或者某一个子任务的执行结果出现细微偏差，后续的所有规划将与预期偏差很大。若

缺乏有效的反馈机制，智能体极易陷入死循环。为应对这一挑战，我们将引入基于 **React** 循环，增加双重裁判机制。通过在每一步操作后强制执行截图，对比前后的视觉信息差异，保证智能体能够实时感知操作是否生效；一旦检测到执行错误或逻辑中断，调度器将触发非线性回溯机制，自动回滚至上一步并尝试替代策略，以此阻断错误的级联传播，确保长程任务的稳定性。

参考文献

- [1] THOMAS J J. Illuminating the path:the research and development agenda for visual analytics [M]. IEEE Computer Society, 2005.
- [2] DIBIA V. LIDA: A Tool for Automatic Generation of Grammar-Agnostic Visualizations and Infographics using Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations). Association for Computational Linguistics, 2023: 113-126.
- [3] TIAN Y, CUI W, DENG D, et al. ChartGPT: Leveraging LLMs to Generate Charts from Abstract Natural Language[J]. IEEE Transactions on Visualization and Computer Graphics, 2024: 1-15.
- [4] WANG H W, GORDON M, BATTLE L, et al. DracoGPT: Extracting Visualization Design Preferences from Large Language Models[M]. arXiv, 2024.
- [5] WANG L, ZHANG S, WANG Y, et al. LLM4Vis: Explainable Visualization Recommendation using ChatGPT[M]. arXiv, 2023.
- [6] ZHANG S, LI H, QU H, et al. AdaVis: Adaptive and Explainable Visualization Recommendation for Tabular Data[J]. IEEE Transactions on Visualization and Computer Graphics, 2024, 30(9): 5923-5938.
- [7] DONG L, CRISAN A. Probing the Visualization Literacy of Vision Language Models: the Good, the Bad, and the Ugly[M]. arXiv, 2025.
- [8] HONG J, SETO C, FAN A, et al. Do LLMs Have Visualization Literacy? An Evaluation on Modified Visualizations to Test Generalization in Data Interpretation[J]. IEEE Transactions on Visualization and Computer Graphics, 2025: 1-13.
- [9] ZENG X, LIN H, YE Y, et al. Advancing Multimodal Large Language Models in Chart Question Answering with Visualization-Referenced Instruction Tuning[J]. IEEE Transactions on Visualization and Computer Graphics, 2025, 31(1): 525-535.
- [10] CHEN C, BAKO H K, YU P, et al. VisAnatomy: An SVG Chart Corpus with Fine-Grained Semantic Labels[M]. arXiv, 2025.
- [11] LIU C, DA C, LONG X, et al. SimVecVis: A Dataset for Enhancing MLLMs in Visualization Understanding[M]. arXiv, 2025.
- [12] CHEN N, ZHANG Y, XU J, et al. VisEval: A Benchmark for Data Visualization in the Era of Large Language Models[J]. IEEE Transactions on Visualization and Computer Graphics, 2024: 1-11.
- [13] SHIN S, HONG S, ELMQVIST N. Visualizationary: Automating Design Feedback for Visualization Designers using LLMs[M]. arXiv, 2025.
- [14] SHAO Z, SHAN Y, HE Y, et al. Do Language Model Agents Align with Humans in Rating Visualizations? An Empirical Study[M]. arXiv, 2025.

-
- [15] WANG H W, HOFFSWELL J, THANE S M T, et al. How Aligned are Human Chart Takeaways and LLM Predictions? A Case Study on Bar Charts with Varying Layouts[M]. arXiv, 2024.
 - [16] ZHAO Y, ZHANG Y, ZHANG Y, et al. LEVA: Using Large Language Models to Enhance Visual Analytics[J]. IEEE Transactions on Visualization and Computer Graphics, 2024: 1-17.
 - [17] LI Z, LI D, GUO Y, et al. ChartGalaxy: A Dataset for Infographic Chart Understanding and Generation[M]. arXiv, 2025.
 - [18] MASRY A, DO X L, TAN J Q, et al. Chartqa: A benchmark for question answering about charts with visual and logical reasoning[C]//Findings of the association for computational linguistics: ACL 2022. 2022: 2263-2279.
 - [19] TANG F, XU H, ZHANG H, et al. A Survey on (M)LLM-Based GUI Agents[M]. arXiv, 2025.
 - [20] ZENG X, LIN H, YE Y, et al. Advancing Multimodal Large Language Models in Chart Question Answering with Visualization-Referenced Instruction Tuning[M]. arXiv, 2024.
 - [21] CHEN X, WU Z, LIU X, et al. Janus-Pro: Unified Multimodal Understanding and Generation with Data and Model Scaling[M]. arXiv, 2025.
 - [22] MASRY A, KAVEHZADEH P, DO X L, et al. UniChart: A Universal Vision-language Pre-trained Model for Chart Comprehension and Reasoning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 14662-14684.
 - [23] KAUR R, SRISHANKAR N, ZENG Z, et al. ChartAgent: A Multimodal Agent for Visually Grounded Reasoning in Complex Chart Question Answering[M]. arXiv, 2025.
 - [24] ZHANG J, KHAYATKHOEI M, CHHIKARA P, et al. Visual Cropping Improves Zero-Shot Question Answering of Multimodal Large Language Models[M]. arXiv, 2023.
 - [25] SURI M, MATHUR P, LIPKA N, et al. ChartLens: Fine-grained Visual Attribution in Charts [C]//CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025: 22447-22462.
 - [26] XIA R, ZHANG B, YE H, et al. ChartX and ChartVLM: A Versatile Benchmark and Foundation Model for Complicated Chart Reasoning[J]. IEEE Transactions on Image Processing, 2024, 34: 7436-7447.
 - [27] NGUYEN D, CHEN J, WANG Y, et al. GUI Agents: A Survey[C]//CHE W, NABENDE J, SHUTOVA E, et al. Findings of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025: 22522-22538.
 - [28] ZHANG C, YANG Z, LIU J, et al. Appagent: Multimodal agents as smartphone users[C]//Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems. 2025: 1-20.
 - [29] DENG X, GU Y, ZHENG B, et al. Mind2web: Towards a generalist agent for the web[J]. Advances in Neural Information Processing Systems, 2023, 36: 28091-28114.
 - [30] XIE T, ZHANG D, CHEN J, et al. Osvorld: Benchmarking multimodal agents for open-ended tasks in real computer environments[J]. Advances in Neural Information Processing Systems, 2024, 37: 52040-52094.

-
- [31] STOLTE C, TANG D, HANRAHAN P. Polaris: a system for query, analysis, and visualization of multidimensional databases[J]. *Commun. ACM*, 2008, 51(11): 75–84.
 - [32] BECKER L T, GOULD E M. Microsoft power BI: extending excel to manipulate, analyze, and visualize diverse data[J]. *Serials Review*, 2019, 45(3): 184-188.
 - [33] LI D, MEI H, SHEN Y, et al. ECharts: A declarative framework for rapid construction of web-based visualization[J]. *Visual Informatics*, 2018, 2(2): 136-146.
 - [34] OPENAI, ACHIAM J, ADLER S, et al. GPT-4 Technical Report[M]. *arXiv*, 2024.
 - [35] HONG W, WANG W, LV Q, et al. CogAgent: A Visual Language Model for GUI Agents[C]// 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 14281-14290.
 - [36] YANG J, ZHANG H, LI F, et al. Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in GPT-4V[M]. *arXiv*, 2023.
 - [37] LU Y, YANG J, SHEN Y, et al. OmniParser for Pure Vision Based GUI Agent[M]. *arXiv*, 2024.
 - [38] GAO D, JI L, BAI Z, et al. Assistgui: Task-oriented pc graphical user interface automation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13289-13298.
 - [39] ZHENG L, WANG R, WANG X, et al. Synapse: Trajectory-as-Exemplar Prompting with Memory for Computer Control[A]. 2024. *arXiv*: 2306.07863.
 - [40] ZHONG W, GUO L, GAO Q, et al. Memorybank: Enhancing large language models with long-term memory[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 38. 2024: 19724-19731.
 - [41] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. *Advances in neural information processing systems*, 2022, 35: 24824-24837.
 - [42] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models [C]//The eleventh international conference on learning representations. 2022.
 - [43] YANG Z, LI L, WANG J, et al. MM-REACT: Prompting ChatGPT for Multimodal Reasoning and Action[M]. *arXiv*, 2023.
 - [44] CHENG K, SUN Q, CHU Y, et al. SeeClick: Harnessing gui grounding for advanced visual gui agents[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 9313-9332.
 - [45] JIANG Z, XIE S, LI W, et al. Zoom in, Click out: Unlocking and Evaluating the Potential of Zooming for GUI Grounding[M]. *arXiv*, 2025.
 - [46] LI W, SHAO Y, YANG J, et al. How Auxiliary Reasoning Unleashes GUI Grounding in VLMs [M]. *arXiv*, 2025.
 - [47] HONG S, ZHUGE M, CHEN J, et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework[A]. 2024. *arXiv*: 2308.00352.
 - [48] WU Q, BANSAL G, ZHANG J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[A]. 2023. *arXiv*: 2308.08155.

-
- [49] CHEN J, SAHA S, BANSAL M. Reconcile: Round-table conference improves reasoning via consensus among diverse llms[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 7066-7085.
- [50] LIANG T, HE Z, JIAO W, et al. Encouraging divergent thinking in large language models through multi-agent debate[C]//Proceedings of the 2024 conference on empirical methods in natural language processing. 2024: 17889-17904.
- [51] SHAO Y, LI L, DAI J, et al. Character-LLM: A Trainable Agent for Role-Playing[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 13153-13187.
- [52] SURİS D, MENON S, VONDRICK C. ViperGPT: Visual Inference via Python Execution for Reasoning[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 11854-11864.
- [53] ZHANG S, LI Z, ZHANG Y, et al. PixelCraft: A Multi-Agent System for High-Fidelity Visual Reasoning on Structured Images[M]. arXiv, 2025.
- [54] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language agents with verbal reinforcement learning[J]. Advances in Neural Information Processing Systems, 2023, 36: 8634-8652.
- [55] MASRY A, ISLAM M S, AHMED M, et al. ChartQAPro: A More Diverse and Challenging Benchmark for Chart Question Answering[C]//CHE W, NABENDE J, SHUTOVA E, et al. Findings of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025: 19123-19151.
- [56] WANG Z, XIA M, HE L, et al. CharXiv: Charting Gaps in Realistic Chart Understanding in Multimodal LLMs[A]. 2024.
- [57] XU Z, DU S, QI Y, et al. ChartBench: A Benchmark for Complex Visual Reasoning in Charts [J]. CoRR, 2023.
- [58] XIE T, LIN M, LIU M, et al. InfoChartQA: A Benchmark for Multimodal Question Answering on Infographic Charts[M]. arXiv, 2025.
- [59] HUANG M, LAI H, ZHANG X, et al. Evochart: A benchmark and a self-training approach towards real-world chart understanding[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 39. 2025: 3680-3688.
- [60] SATYANARAYAN A, MORITZ D, WONGSUPHASAWAT K, et al. Vega-Lite: A Grammar of Interactive Graphics[J]. IEEE Transactions on Visualization and Computer Graphics, 2017, 23(1): 341-350.